

CRISTIANO MENDIETA

MODELAGEM DA DIFUSÃO DE TENDÊNCIAS CULTURAIS COM REDES NEURAIIS
HETEROGÊNEAS TEMPORAIS EM GRAFOS

(versão pré-defesa, compilada em 13 de julho de 2026)

Documento apresentado como requisito parcial ao exame de qualificação de Mestrado no Programa de Pós-Graduação em Informática, Setor de Ciências Exatas, da Universidade Federal do Paraná.

Área de concentração: *Computação*.

Orientador: André Luís Vignatti.

CURITIBA PR

2026

RESUMO

por quê?

Modelos epidemiológicos como o SIR oferecem uma **leitura interpretável** da difusão de conteúdos culturais em plataformas de streaming, mas operam sobre curvas de popularidade agregadas e não capturam a estrutura relacional entre músicas, artistas e gêneros que também condiciona essa difusão. Este trabalho investiga em que medida uma rede neural em grafo heterogêneo com componente temporal explícito melhora a modelagem da difusão musical em relação a esse baseline populacional. A partir do ecossistema de dados do MGD+ combinado a rankings diários do Spotify (Top 200 e Viral 50) no mercado brasileiro entre 2017 e 2021, constrói-se um grafo heterogêneo com 6.526 músicas, 1.701 artistas e 530 gêneros, conectados por relações de autoria, associação a gênero, coocorrência de gêneros e cotrajetória de popularidade. Sobre esse grafo treina-se o MUSICDIFFUSIONGNN, que combina um codificador **HeteroGraphSAGE por snapshots semanais com uma cabeça recorrente GRU**, comparado ao baseline SIR sob dois regimes: reconstrução retroativa da curva completa (Modo 1) e previsão causal a k semanas à frente usando apenas informação passada (Modo 2). O baseline SIR foi antes reproduzido com fidelidade ao trabalho de referência (RMSE de viralidade 0,0289 e de sucesso 0,0471, 1.981 músicas), e o grafo construído apresentou estrutura topológica não aleatória, com **clustering elevado e comunidades de gênero coerentes**. No Modo 1, o SIR obtém menor RMSE por ajustar dois parâmetros livres à curva completa de cada música, uma vantagem estrutural do regime *in-sample*, embora a diferença se estreite nas semanas em que a música está de fato no chart. No Modo 2, que corresponde ao uso pretendido de um preditor, a GNN supera o SIR nos seis cenários avaliados (dois charts $\times$ três horizontes), com significância estatística forte (Wilcoxon pareado, p entre $6,5 \times 10^{-4}$ e $5,4 \times 10^{-32}$) e menor erro em 64% a 77% das músicas, superando também o baseline de persistência nos horizontes mais longos. Esses resultados indicam que a GNN supera ambos os baselines nos horizontes mais longos, com vantagem sobre o SIR que cresce com o horizonte; se esse ganho decorre especificamente da estrutura relacional do grafo, e não apenas da maior flexibilidade de um preditor neural treinado frente a um ajuste de dois parâmetros, é uma questão que permanece em aberto. Como trabalho em andamento, permanecem a análise de interpretabilidade da GNN (ablação por tipo de aresta, importância de atributos e extração de análogos de β , γ e R_0) e um baseline neural sem grafo, a serem incorporados na versão final da dissertação.

Palavras-chave: Difusão cultural. Redes neurais em grafos. Grafos temporais heterogêneos. Streaming musical. Vídeo curto.

SUMÁRIO

1	INTRODUÇÃO	5
2	FUNDAMENTAÇÃO TEÓRICA.	7
2.1	REDES SOCIAIS, PLATAFORMAS DIGITAIS E DIFUSÃO CULTURAL . . .	7
2.2	DIFUSÃO DE INFORMAÇÃO E MODELOS DE CONTÁGIO	7
2.3	GRAFOS HETEROGÊNEOS E TEMPORAIS	8
2.4	REDES NEURAIIS EM GRAFOS	9
2.5	GRAFOS TEMPORAIS E APRENDIZADO EM GRAFOS DINÂMICOS. . . .	10
2.6	SÍNTESE DO CAPÍTULO	10
3	TRABALHOS RELACIONADOS	11
3.1	DIFUSÃO DE INFORMAÇÃO E MODELOS DE CONTÁGIO	11
3.2	REDES NEURAIIS EM GRAFOS HETEROGÊNEOS E TEMPORAIS	12
3.3	PREVISÃO DE POPULARIDADE E SUCESSO MUSICAL	13
3.4	POSICIONAMENTO E LACUNA.	13
4	DADOS E METODOLOGIA	15
4.1	VISÃO GERAL DO DESENHO EXPERIMENTAL	15
4.2	FONTES DE DADOS	15
4.3	PRÉ-PROCESSAMENTO DAS SÉRIES MUSICAIS	16
4.4	BASELINE SIR.	16
4.5	CONSTRUÇÃO DO GRAFO HETEROGÊNEO	17
4.6	TEMPORALIDADE E PREVENÇÃO DE VAZAMENTO	18
4.7	MODELO PROPOSTO.	18
4.7.1	Codificador espacial heterogêneo.	19
4.7.2	Snapshots temporais e banco de <i>embeddings</i>	19
4.7.3	Cabeça temporal recorrente.	20
4.7.4	Função de perda, otimização e regularização.	20
4.8	PROTOCOLO EXPERIMENTAL	21
4.9	SÍNTESE DO CAPÍTULO	22
5	RESULTADOS PARCIAIS	23
5.1	REPRODUÇÃO DO BASELINE SIR	23
5.2	GRAFO HETEROGÊNEO TEMPORAL	24
5.3	AVALIAÇÃO DUPLA: GNN TEMPORAL <i>VERSUS</i> SIR.	25
5.3.1	Modo 1: reconstrução retroativa	25
5.3.2	Modo 2: previsão de curto horizonte	26
5.4	DISCUSSÃO PARCIAL	27

6	CRONOGRAMA E PRÓXIMOS PASSOS	28
6.1	PRÓXIMOS PASSOS	28
6.2	CRONOGRAMA	29
	REFERÊNCIAS	30

1 INTRODUÇÃO

A circulação de conteúdos culturais em plataformas digitais tornou-se um fenômeno central para compreender como músicas, vídeos, estilos, linguagens e tendências alcançam visibilidade em larga escala. Em serviços de streaming musical, rankings diários de popularidade e viralidade registram a trajetória de músicas que emergem, atingem picos de atenção e desaparecem gradualmente. Em plataformas de vídeo curto, por exemplo, sons, hashtags e formatos audiovisuais também se combinam em ciclos rápidos de adoção e remixagem. Em ambos os casos, a difusão cultural não ocorre apenas como uma série temporal agregada: ela é mediada por relações entre entidades distintas e por dependências temporais.

Modelos clássicos de difusão, incluindo formulações inspiradas em epidemiologia e em cascatas de influência, oferecem uma primeira aproximação para esse problema (Kempe et al., 2003; Oliveira et al., 2025b). Ao representar a popularização de um conteúdo como processo de contágio, modelos como SIR e SIS permitem estimar parâmetros globais de adoção, persistência e declínio. Essa leitura é útil porque transforma curvas de popularidade em objetos matemáticos interpretáveis. Entretanto, tais modelos tendem a operar sobre populações agregadas e, por isso, têm dificuldade para representar a estrutura relacional que condiciona a difusão: artistas compartilham gêneros, músicas apresentam trajetórias semelhantes, gêneros se relacionam por coocorrência e diferentes faixas podem ocupar nichos culturais próximos.

Este projeto parte da hipótese de que redes neurais em grafos heterogêneos com componente temporal são mais adequadas para modelar esse tipo de fenômeno no contexto de streaming musical brasileiro. A heterogeneidade permite representar múltiplos tipos de nós e arestas; a dimensão temporal permite distinguir relações já observáveis em um instante das relações que só aparecem no futuro; e o aprendizado neural em grafos permite combinar atributos locais, estrutura de vizinhança e evolução temporal em uma mesma representação. Assim, a proposta desloca o foco de curvas populacionais isoladas para grafos dinâmicos nos quais a difusão cultural emerge da interação entre músicas, artistas, gêneros e trajetórias de popularidade.

A investigação concentra-se, neste momento, no domínio de música como objeto empírico principal. O projeto reproduz um baseline epidemiológico baseado em SIR sobre charts brasileiros e constrói um grafo heterogêneo temporal envolvendo músicas, artistas e gêneros, a partir do ecossistema de dados do MGD+ (Seufitelli et al., 2023). Essa escolha permite comparar diretamente modelos populacionais e modelos baseados em grafos em um cenário já parcialmente consolidado, com dados de streaming musical brasileiro e métricas de viralidade e sucesso derivadas de rankings diários.

A pergunta central que orienta o trabalho é: em que medida a estrutura heterogênea e a dinâmica temporal explícita melhoram a modelagem de difusão de músicas em plataformas brasileiras de streaming, em comparação com baselines populacionais e GNNs estáticas? Essa

pergunta se desdobra em três subquestões. Primeiro, interessa avaliar se uma rede neural em grafo heterogêneo temporal sobre relações artista–música–gênero supera o ajuste SIR em tarefas de reconstrução e predição de viralidade e sucesso. Segundo, busca-se entender quais tipos de relação contribuem mais para a previsibilidade, incluindo autoria, associação a gêneros, coocorrência entre gêneros e similaridade de trajetória entre músicas. Terceiro, **investiga-se em que medida a interpretabilidade epidemiológica do baseline pode ser preservada ao se incorporar estrutura relacional**, isto é, se o modelo em grafo ainda permite recuperar quantidades com significado epidemiológico, como taxas de adoção e declínio, em vez de operar apenas como caixa-preta. **→ IMPORTANTE SABER SUSTENTAR ISSO**

Além do interesse científico dessas questões, o problema tem valor aplicado imediato. Um preditor confiável de curto horizonte para a trajetória de popularidade de uma faixa subsidiaria decisões hoje tomadas majoritariamente por inspeção manual das curvas de chart, como a priorização de faixas para curadoria de playlist, a alocação de investimento promocional e a detecção antecipada de músicas em ascensão. **BOM PARÁGRAFO PARA OS SLIDES**

As contribuições esperadas deste projeto são duas. Primeiro, construir uma representação em grafo heterogêneo temporal para o domínio musical, permitindo avaliar o ganho marginal de relações como autoria, gênero, coocorrência e similaridade de trajetória. Segundo, comparar modelos populacionais, GNNs estáticas e GNNs temporais em um mesmo pipeline experimental, produzindo uma análise sobre o papel de **homofilia**, estrutura relacional e temporalidade na previsibilidade da difusão musical. **→ SABER EXPLICAR ESSE TERMO**

Este documento de qualificação está organizado da seguinte forma. O Capítulo 2 apresenta os conceitos necessários para a proposta, incluindo redes sociais, difusão de informação, modelos epidemiológicos, grafos heterogêneos temporais e redes neurais em grafos. Os capítulos seguintes deverão detalhar os trabalhos relacionados, os dados e métodos da linha musical, os resultados parciais já obtidos e o cronograma de execução da dissertação.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os conceitos que sustentam a proposta de modelar difusão cultural por meio de grafos heterogêneos temporais e redes neurais em grafos. A organização segue uma progressão conceitual: primeiro são discutidas redes sociais e plataformas digitais; em seguida, processos de difusão e modelos epidemiológicos; depois, grafos heterogêneos e temporais; por fim, redes neurais em grafos.

2.1 REDES SOCIAIS, PLATAFORMAS DIGITAIS E DIFUSÃO CULTURAL

Redes sociais podem ser entendidas como estruturas compostas por entidades e relações. As entidades podem representar pessoas, artistas, músicas, gêneros, vídeos ou outros objetos culturais. As relações indicam formas de associação, como autoria, consumo, similaridade, coocorrência, compartilhamento de uma categoria ou adoção de uma tendência. Em plataformas digitais, essas relações deixam rastros observáveis em larga escala, permitindo estudar fenômenos culturais como processos estruturados de circulação.

No caso de músicas em serviços de streaming, a visibilidade de uma faixa pode ser acompanhada por rankings diários de popularidade e viralidade. Esses rankings sintetizam a atenção recebida por uma música ao longo do tempo, mas não explicam sozinhos por que certas trajetórias são semelhantes, por que alguns gêneros concentram mais hits, ou por que artistas associados a determinados nichos apresentam padrões parecidos de difusão. Para responder a essas perguntas, é necessário representar também as relações entre músicas, artistas e gêneros.

A difusão de tendências culturais em outras plataformas, como vídeos curtos, reforça a mesma intuição geral: conteúdos não circulam isoladamente, mas associados a formatos, sons, categorias, comunidades e padrões de reutilização. Este trabalho, contudo, utiliza esse fenômeno apenas como motivação ampla. O foco empírico desta qualificação é a difusão musical em charts brasileiros de streaming, onde as entidades e relações observáveis permitem construir um grafo heterogêneo temporal diretamente alinhado aos dados disponíveis.

2.2 DIFUSÃO DE INFORMAÇÃO E MODELOS DE CONTÁGIO

A difusão de informação estuda como itens, comportamentos ou estados se propagam por uma população ou rede. Em uma formulação abstrata, um conteúdo pode ser adotado por alguns indivíduos e, a partir deles, alcançar novos indivíduos ao longo do tempo. Essa ideia aproxima a difusão informacional de modelos de contágio, nos quais a exposição a vizinhos, conteúdos ou sinais aumenta a probabilidade de adoção.

Modelos clássicos de difusão em redes, como Independent Cascade e Linear Threshold, descrevem a propagação a partir de interações locais (Kempe et al., 2003). No Independent

Cascade, nós ativados têm oportunidades probabilísticas de ativar seus vizinhos. No Linear Threshold, um nó adota um comportamento quando a influência acumulada de seus vizinhos ultrapassa um limiar. Esses modelos são importantes porque tornam explícito que a estrutura da rede afeta o alcance da difusão: a posição dos nós, a força das conexões e os caminhos disponíveis alteram o resultado final do processo.

Outra abordagem relevante é a dos modelos epidemiológicos compartimentais. Neles, a população é dividida em estados, e equações diferenciais descrevem a transição entre esses estados. No modelo SIR, indivíduos suscetíveis podem tornar-se infectados e, posteriormente, removidos. Ao transpor essa formulação para difusão musical, o estado infectado pode ser interpretado como atenção ativa a uma música, enquanto os parâmetros do modelo representam taxas agregadas de adoção e abandono.

A formulação SIR clássica é dada por:

$$\frac{dS}{dt} = -\beta SI, \quad (2.1)$$

$$\frac{dI}{dt} = \beta SI - \gamma I, \quad (2.2)$$

$$\frac{dR}{dt} = \gamma I, \quad (2.3)$$

em que S representa a fração suscetível, I a fração infectada, R a fração removida, β a taxa de contágio e γ a taxa de remoção. A razão $R_0 = \beta/\gamma$ fornece uma medida agregada da capacidade de propagação do processo.

Apesar de sua interpretabilidade, modelos compartimentais possuem uma limitação importante para o problema desta dissertação: eles tendem a resumir a difusão em poucos parâmetros globais. Essa simplificação é útil como baseline, mas não captura diretamente heterogeneidade de entidades, tipos distintos de relação, atributos de conteúdo e mudanças estruturais ao longo do tempo. Por isso, este trabalho usa modelos epidemiológicos como ponto de comparação, não como representação final do fenômeno.

2.3 GRAFOS HETEROGÊNEOS E TEMPORAIS

Um grafo $G = (V, E)$ é composto por um conjunto de nós V e um conjunto de arestas E . Em grafos homogêneos, todos os nós e arestas são tratados como pertencentes a um mesmo tipo. Essa simplificação é adequada para muitos problemas, mas é insuficiente quando o domínio contém entidades semanticamente diferentes. Em difusão musical, uma música, um artista e um gênero não exercem o mesmo papel; da mesma forma, uma relação de autoria não tem o mesmo significado que uma relação de coocorrência.

Grafos heterogêneos representam explicitamente múltiplos tipos de nós e arestas. Neste projeto, o grafo contém nós de música, artista e gênero, conectados por relações como *performs*,

has_genre, *cotrjectory* e *cooccurs*. Cada tipo de aresta expressa uma hipótese diferente sobre a difusão: artistas conectam repertórios, gêneros expressam homofilia cultural, coocorrências indicam proximidade entre categorias e trajetórias semelhantes aproximam músicas com padrões temporais parecidos.

A dimensão temporal acrescenta outra restrição fundamental. Em tarefas preditivas, o modelo não deve usar relações que só se tornam observáveis no futuro. Por isso, cada aresta pode receber um tempo de primeira observação, permitindo construir snapshots do grafo até uma semana específica. Essa prática reduz vazamento temporal e aproxima a avaliação do cenário real: prever a evolução de uma música usando apenas a informação disponível até o instante de previsão.

No contexto musical deste trabalho, a temporalidade aparece em dois níveis. O primeiro é a própria série diária de posição ou pontuação de uma música nos charts. O segundo é a evolução do grafo, pois relações derivadas de coocorrência ou de similaridade de trajetória só devem ser consideradas quando já são observáveis. A combinação desses níveis permite avaliar se a estrutura do grafo melhora a previsão em relação ao uso isolado da curva temporal.

2.4 REDES NEURAIIS EM GRAFOS

Redes neurais em grafos, ou Graph Neural Networks (GNNs), são modelos projetados para aprender representações de nós, arestas ou grafos inteiros a partir de atributos locais e estrutura relacional. A ideia central é a passagem de mensagens: cada nó atualiza sua representação agregando informações de seus vizinhos. Após múltiplas camadas, a representação de um nó incorpora informações de uma vizinhança progressivamente maior.

Em uma forma geral, uma camada de GNN pode ser descrita por duas operações: agregação e atualização. A agregação combina mensagens provenientes dos vizinhos; a atualização transforma a representação anterior do nó e a mensagem agregada em uma nova representação. Diferentes arquiteturas se distinguem pela forma de normalizar vizinhos, ponderar mensagens, incorporar atenção ou lidar com diferentes tipos de aresta.

Graph Convolutional Networks (GCNs) introduzem uma forma de convolução sobre grafos por meio de agregação normalizada de vizinhos (Kipf e Welling, 2017). GraphSAGE enfatiza aprendizado indutivo, permitindo gerar embeddings para nós não vistos a partir de funções de agregação (Hamilton et al., 2017). Graph Attention Networks (GATs) incorporam mecanismos de atenção para atribuir pesos diferentes aos vizinhos (Veličković et al., 2018). Essas arquiteturas são fundamentais para compreender a família de modelos que este projeto utiliza como baseline ou componente metodológico.

Em grafos heterogêneos, a passagem de mensagens precisa respeitar os tipos de nós e relações. Modelos como Heterogeneous Graph Transformer e variações de HetGNN lidam com essa diversidade por meio de parâmetros específicos por tipo, atenção sobre relações ou agregações especializadas (Hu et al., 2020). Essa capacidade é especialmente relevante neste

projeto, pois a influência de um artista sobre uma música não deve ser tratada da mesma forma que a relação entre dois gêneros ou entre duas músicas com trajetórias semelhantes.

2.5 GRAFOS TEMPORAIS E APRENDIZADO EM GRAFOS DINÂMICOS

Grafos temporais representam relações que mudam ao longo do tempo. Em vez de assumir uma estrutura fixa, o modelo observa eventos, snapshots ou sequências de interações, preservando a ordem em que as conexões surgem. Essa perspectiva é essencial para a difusão musical, pois o significado de uma conexão depende de quando ela ocorre. Uma música pode entrar em um chart, passar a compartilhar trajetória com outra ou se associar a um gênero, e o momento em que cada um desses eventos acontece altera a forma como a relação deve ser interpretada.

A literatura costuma distinguir duas formas de modelar grafos temporais (Kazemi et al., 2020). A primeira discretiza o tempo em snapshots, criando uma sequência de grafos estáticos (grafos dinâmicos em tempo discreto). Essa abordagem é simples e compatível com GNNs tradicionais, sendo particularmente adequada quando os dados são naturalmente agregados por dias ou semanas, como em EvolveGCN e DySAT (Pareja et al., 2020; Sankar et al., 2020). A segunda trata o grafo como uma sequência contínua de eventos temporais (grafos dinâmicos em tempo contínuo), preservando timestamps individuais e permitindo atualizar representações conforme novas interações ocorrem, como em TGAT e TGN (Xu et al., 2020; Rossi et al., 2020).

Nesta qualificação, a estratégia inicial é baseada em snapshots semanais do grafo musical. Relações observáveis até uma semana t são utilizadas para prever viralidade ou sucesso em instantes posteriores, evitando que informações futuras entrem no treinamento ou na avaliação. Essa formulação permite comparar três famílias de modelos: baselines epidemiológicos, GNNs estáticas treinadas sobre uma versão agregada do grafo e GNNs temporais que respeitam a evolução das relações.

2.6 SÍNTESE DO CAPÍTULO

Os conceitos apresentados neste capítulo delimitam o espaço metodológico da dissertação. Modelos epidemiológicos oferecem baselines interpretáveis para curvas de difusão, mas comprimem a estrutura relacional em poucos parâmetros. Grafos heterogêneos temporais permitem representar músicas, artistas, gêneros e relações distintas respeitando a ordem de observação dos dados. Redes neurais em grafos oferecem mecanismos para aprender a partir dessa estrutura e comparar, de forma controlada, o ganho de usar relações heterogêneas e temporais no problema de difusão musical. O próximo passo do documento será posicionar essa combinação em relação aos trabalhos existentes e, em seguida, detalhar os dados e experimentos já conduzidos no dataset de Spotify/MGD+.

SABER EXPLICAR A DECISÃO
E SE FAZ SENTIDO A OUTRA ABORDAGEM

3 TRABALHOS RELACIONADOS

A difusão de uma música nos charts é, ao mesmo tempo, um fenômeno de contágio, em que uma faixa se espalha por uma população de ouvintes ao longo do tempo, e um fenômeno relacional, em que esse espalhamento é mediado por artistas, gêneros e trajetórias que conectam faixas entre si. Capturar os dois aspectos exige reunir literaturas que costumam permanecer separadas. Este capítulo as organiza em três linhas: os modelos de difusão de informação e contágio, que descrevem a dinâmica temporal da adoção em nível populacional; as redes neurais em grafos heterogêneos e temporais, que representam a estrutura relacional e sua evolução; e a previsão de popularidade e sucesso musical, que delimita o problema preditivo e seus dados. Para cada linha interessa o que ela já oferece, onde se limita e por que sua combinação ainda não foi explorada para a difusão musical em charts brasileiros de streaming. É dessa leitura que emerge a lacuna formalizada na última seção, a qual motiva a proposta da dissertação.

3.1 DIFUSÃO DE INFORMAÇÃO E MODELOS DE CONTÁGIO

O estudo da difusão de inovações e comportamentos tem raízes anteriores às plataformas digitais. Rogers (2003) consolidou a teoria da difusão de inovações, descrevendo como uma novidade se espalha por uma população ao longo do tempo segundo curvas de adoção tipicamente sigmóides. Na mesma tradição, o modelo de Bass (1969) formalizou a adoção de produtos por meio de coeficientes de inovação e imitação, oferecendo uma das primeiras descrições paramétricas e ajustáveis de curvas de difusão, um antecedente direto da leitura epidemiológica adotada nesta dissertação.

Quando a difusão passa a ser mediada por uma rede, a estrutura das conexões torna-se determinante. Granovetter (1978) propôs modelos de limiar para comportamento coletivo, nos quais um indivíduo adota um comportamento apenas quando uma fração suficiente de seus contatos já o adotou. Watts (2002) mostrou, com um modelo simples de cascatas em redes aleatórias, que grandes cascatas globais são possíveis mas raras, e dependem fortemente da conectividade e da distribuição de limiares. Essa linha culmina, do ponto de vista algorítmico, no trabalho de Kempe et al. (2003), que formalizou os modelos Independent Cascade e Linear Threshold e o problema de maximização de influência. Esses modelos tornam explícito que a topologia da rede condiciona o alcance da difusão, mas operam sobre grafos homogêneos e tipicamente sobre um único tipo de relação.

No contexto de conteúdo online, dois trabalhos ajudam a caracterizar a difusão para além do volume agregado. Goel et al. (2016) introduziram a noção de *virality estrutural*, distinguindo conteúdos que se espalham por difusão de muitos passos daqueles impulsionados por uma única transmissão massiva. Zhao et al. (2015), por sua vez, modelaram a popularidade de publicações por meio de processos pontuais auto-excitados, prevendo o tamanho final de uma cascata a partir

de sua dinâmica inicial. Esses trabalhos aproximam difusão e previsão de popularidade, mas permanecem centrados em uma única modalidade de interação (compartilhamento ou retweet) e não exploram a heterogeneidade de entidades.

A aplicação de modelos compartimentais a fenômenos culturais é mais recente e diretamente relevante a esta proposta. Oliveira et al. (2025b) ajustaram um modelo SIR a curvas de viralidade e sucesso de músicas em charts brasileiros, estimando parâmetros de adoção e remoção por faixa e estabelecendo o baseline epidemiológico que esta dissertação reproduz. Extensões posteriores incorporaram comportamento multi-onda a essas curvas (Oliveira et al., 2025a). O ganho dessa abordagem é a interpretabilidade: poucos parâmetros resumem a trajetória de cada música. A limitação, contudo, é estrutural: o ajuste é feito música a música, de forma isolada, sem representar que artistas, gêneros e trajetórias semelhantes condicionam a difusão.

3.2 REDES NEURAIIS EM GRAFOS HETEROGÊNEOS E TEMPORAIS

As redes neurais em grafos oferecem um caminho para incorporar exatamente a estrutura relacional que os modelos de contágio agregados deixam de fora. As arquiteturas fundamentais (GCN (Kipf e Welling, 2017), GraphSAGE (Hamilton et al., 2017) e GAT (Veličković et al., 2018)) estabeleceram o paradigma de passagem de mensagens para grafos homogêneos, diferindo na forma de normalizar, amostrar ou ponderar vizinhos. Esses modelos, no entanto, tratam todos os nós e arestas como de um único tipo.

Para domínios com entidades e relações semanticamente distintas, surgiram as GNNs heterogêneas. A R-GCN (Schlichtkrull et al., 2018) introduziu parâmetros específicos por tipo de relação, permitindo modelar grafos de conhecimento com múltiplas arestas. A HAN (Wang et al., 2019) combinou atenção em nível de nó e de *meta-caminho*, e o *Heterogeneous Graph Transformer* (Hu et al., 2020) generalizou a atenção por tipo de nó e aresta. Essas arquiteturas justificam a escolha, nesta dissertação, de um codificador que trate os diferentes tipos de relação com parâmetros próprios, em vez de reduzi-los a um grafo homogêneo.

A dimensão temporal foi incorporada por duas famílias de abordagens, conforme discutido na fundamentação. A primeira discretiza o tempo em *snapshots* e combina uma GNN com um módulo recorrente: a *Graph Convolutional Recurrent Network* (Seo et al., 2018) encadeia convoluções em grafo e células recorrentes, e a EvolveGCN (Pareja et al., 2020) faz os próprios pesos da GNN evoluírem no tempo. A DySAT (Sankar et al., 2020) aplica autoatenção tanto na estrutura quanto na sequência de snapshots. A segunda família preserva os *timestamps* individuais e atualiza representações por evento: a TGAT (Xu et al., 2020) introduz uma codificação temporal funcional sobre a vizinhança, e a TGN (Rossi et al., 2020) mantém memória por nó atualizada a cada interação. Levantamentos da área sistematizam esse espaço de projeto (Kazemi et al., 2020). A arquitetura proposta nesta dissertação situa-se claramente na primeira família (*snapshots* semanais codificados por uma GNN heterogênea e agregados por uma rede recorrente), escolha justificada pelo grão semanal das relações do grafo e pelo

custo computacional. As variantes contínuas, como a TGN, permanecem como alternativa para cenários de granularidade mais fina.

Apesar da maturidade dessas arquiteturas, sua aplicação conjunta (heterogeneidade e temporalidade) ao problema específico de difusão musical é escassa, e praticamente inexistente sobre dados brasileiros de streaming.

3.3 PREVISÃO DE POPULARIDADE E SUCESSO MUSICAL

A previsão de sucesso musical é estudada há quase duas décadas sob o rótulo de *hit song science*. Dhanaraj e Logan (2005) foram dos primeiros a prever hits a partir de atributos de áudio e letra. Pouco depois, Pachet e Roy (2008) contestaram esses resultados, argumentando que atributos acústicos isolados têm poder preditivo limitado, um debate que permanece pertinente e que recomenda cautela ao tratar features de conteúdo como suficientes. Trabalhos mais recentes retomaram o problema com aprendizado profundo: Yang et al. (2017) aplicaram redes convolucionais a espectrogramas para prever popularidade, e Interiano et al. (2018) analisaram tendências e a previsibilidade do sucesso em décadas de músicas dos charts, encontrando previsibilidade modesta porém significativa a partir de características de áudio.

Do ponto de vista de dados, o MGD+ (Seufitelli et al., 2023) consolidou metadados, atributos acústicos e séries de charts em escala global, viabilizando estudos reprodutíveis de difusão e popularidade. É sobre esse ecossistema, combinado a rankings diários de Top 200 e Viral 50, que esta dissertação se apoia.

O traço comum dessa literatura é o predomínio de representações tabulares ou de conteúdo: cada música é descrita por seu próprio vetor de atributos, e o sucesso é previsto de forma quase independente entre faixas. Raramente a estrutura relacional (coautoria, compartilhamento de gênero, similaridade de trajetória) ou a dinâmica temporal explícita da difusão são incorporadas ao modelo preditivo.

3.4 POSICIONAMENTO E LACUNA

As três linhas revisadas são complementares e, em conjunto, delimitam a contribuição desta dissertação. Os modelos de difusão e contágio oferecem interpretabilidade e capturam a dinâmica temporal, mas operam em nível populacional e ignoram a heterogeneidade de entidades; é o caso do baseline SIR aplicado a charts brasileiros (Oliveira et al., 2025b). As GNNs heterogêneas e temporais oferecem exatamente a representação relacional e dinâmica ausente nos modelos de contágio, mas foram pouco aplicadas à difusão musical e quase nunca a dados brasileiros. A literatura de previsão de popularidade musical, por fim, domina o uso de atributos de conteúdo, mas tende a tratar as músicas isoladamente, sem grafo nem difusão explícita.

A lacuna que emerge é a ausência de um trabalho que (i) represente a difusão musical como um grafo heterogêneo temporal de músicas, artistas e gêneros; (ii) compare diretamente esse modelo a um baseline epidemiológico interpretável e já consolidado na literatura brasileira; e (iii)

o faça sob um protocolo de avaliação que respeite a ordem temporal de observação das relações. É precisamente nesse ponto que esta dissertação se insere: ao confrontar um modelo populacional, GNNs estáticas e uma GNN heterogênea temporal em um mesmo pipeline experimental sobre charts brasileiros, busca-se quantificar o ganho marginal da estrutura relacional e da temporalidade na previsibilidade da difusão musical.

4 DADOS E METODOLOGIA

Este capítulo descreve os dados e o protocolo metodológico do estudo, dedicado à difusão musical em charts brasileiros. A organização parte do pressuposto de que os conceitos de SIR, grafos heterogêneos, redes neurais em grafos e grafos temporais já foram apresentados na fundamentação teórica. Assim, o foco aqui é operacional: quais dados são usados, como eles são transformados em um grafo heterogêneo temporal, quais modelos serão comparados e como a avaliação será conduzida.

4.1 VISÃO GERAL DO DESENHO EXPERIMENTAL

O estudo tem como objetivo comparar um baseline epidemiológico, baseado em SIR, com uma arquitetura neural em grafo heterogêneo temporal para previsão de difusão musical. O domínio empírico é composto por músicas presentes em charts brasileiros de streaming, especialmente Top 200 e Viral 50. A hipótese operacional é que a estrutura relacional entre músicas, artistas e gêneros acrescenta informação preditiva que não está disponível em modelos ajustados apenas sobre curvas agregadas.

O desenho experimental segue três etapas. Primeiro, reproduz-se o baseline SIR sobre séries de viralidade e sucesso, de forma alinhada ao trabalho de referência (Oliveira et al., 2025b). Segundo, constrói-se um grafo heterogêneo com nós de música, artista e gênero, preservando atributos e tempos de observação das relações. Terceiro, treina-se uma GNN heterogênea com componente temporal para prever valores futuros de *rank-score* e comparar seu desempenho com o baseline.

4.2 FONTES DE DADOS

A base principal é o MGD+, que fornece metadados musicais e atributos acústicos associados a músicas e artistas (Seufitelli et al., 2023). Esses dados são combinados a séries de charts brasileiros do Spotify, em particular rankings diários de Top 200 e Viral 50. O Top 200 é usado como aproximação de sucesso ou popularidade consolidada, enquanto o Viral 50 representa sinais de crescimento e circulação viral.

O universo atual do estudo contém 6.526 músicas, 1.701 artistas e 530 gêneros. Esses elementos formam os três tipos de nós do grafo heterogêneo. As músicas carregam atributos acústicos, indicadores de popularidade e variáveis derivadas dos charts; os artistas carregam estatísticas agregadas de presença em charts e diversidade de gêneros; os gêneros, por não terem atributos próprios no dataset, são representados por embeddings aprendidos pelo próprio modelo durante o treinamento (Seção 4.7).

A cobertura temporal considerada vai de 2017 a 2021. Essa janela permite separar treinamento, validação e teste de forma cronológica, evitando que informações futuras contaminem a avaliação. A separação temporal também é compatível com a formulação de snapshots semanais usada no grafo.

* SLIDE BEM FEITO SOBRE AS ETAPAS DO PRÉ-PROCESSAMENTO

4.3 PRÉ-PROCESSAMENTO DAS SÉRIES MUSICAIS

SABER BEM SOBRE ESSA NORMALIZAÇÃO

O pré-processamento das séries segue a lógica do estudo SIR de referência para manter comparabilidade. Rankings diários são transformados em séries numéricas de *rank-score*, separando a dimensão de viralidade, associada ao Viral 50, e a dimensão de sucesso, associada ao Top 200. Essa transformação converte posições de ranking em valores comparáveis entre músicas e datas. Para uma música em uma posição *rank* de um chart com posição máxima *max_rank* (200 no Top 200 e 50 no Viral 50), o *rank-score* é definido por

$$\text{rank_score} = \text{max_rank} - \text{rank} + 1, \quad (4.1)$$

de modo que a posição #1 receba o valor máximo. Sobre essa série aplica-se uma média móvel de sete dias, seguida de normalização *min-max* para o intervalo $[0, 0,5]$; dias em que a música não aparece no chart recebem um valor mínimo de 0,001, evitando problemas numéricos no ajuste do SIR. Os limites dessa normalização são teóricos e fixos (*max_rank* conhecido a priori e o piso 0,001), não estimados empiricamente sobre a série de cada música, de modo que o alvo não carregue informação do pico futuro da trajetória. Cada música gera, portanto, duas séries de aproximadamente 1.900 dias: uma de viralidade e uma de sucesso.

Músicas sem atributos acústicos completos não são removidas do universo. Em vez disso, os valores ausentes são imputados com a mediana e **acompanhados por um indicador binário** de ausência acústica. Essa decisão preserva a cobertura do dataset e permite que o modelo aprenda se a ausência de atributos carrega algum sinal sistemático.

As variáveis contínuas usadas como atributos são padronizadas por *score-z*, com média e desvio-padrão estimados exclusivamente sobre o *split* de treinamento (Seção 4.6) e reaplicados a validação e teste. Essa normalização é aplicada a atributos como popularidade, streams, dias em chart e estatísticas agregadas de artistas. O objetivo é evitar que diferenças de escala dominem a passagem de mensagens na GNN, sem introduzir vazamento de informação futura nas estatísticas de normalização.

IMPORTANTE SABER EXPLICAR BEM

4.4 BASELINE SIR

O baseline SIR modela a trajetória de cada música como um processo de contágio agregado. A curva observada de *rank-score* é ajustada por meio dos parâmetros β e γ , que representam, respectivamente, taxa de adoção e taxa de remoção. A razão $R_0 = \beta/\gamma$ resume o potencial de espalhamento da música segundo a leitura epidemiológica.

Esse baseline tem duas funções no projeto. A primeira é metodológica: reproduzir o resultado do estudo de referência e verificar se o pipeline local alcança erros compatíveis. A segunda é conceitual: oferecer uma comparação interpretável para avaliar se o aumento de complexidade trazido por GNNs heterogêneas se traduz em ganho empírico.

A métrica principal para essa etapa é o RMSE, calculado separadamente para viralidade e sucesso. O critério mínimo do estudo é obter desempenho compatível com o paper de referência dentro de uma margem aceitável. Uma vez validado esse baseline, a comparação passa a incluir a predição genuína de valores futuros, e não apenas o ajuste retroativo da curva observada.

4.5 CONSTRUÇÃO DO GRAFO HETEROGÊNEO

O grafo proposto possui três tipos de nós: `music`, `artist` e `genre`. Essa escolha reflete a hipótese de que a difusão musical depende simultaneamente das propriedades da faixa, do histórico dos artistas associados e da proximidade cultural expressa por gêneros.

As músicas são descritas por vetores de 12 dimensões, compostos por nove atributos acústicos, indicador de conteúdo explícito, tipo de música e um indicador binário de ausência acústica. Os artistas são descritos por uma única dimensão: o número de gêneros associados. Como os gêneros não possuem atributos descritivos no dataset, são representados por embeddings de 32 dimensões inicializados aleatoriamente e aprendidos como parâmetros do modelo, junto com os demais pesos, durante o treinamento (Seção 4.7). Deliberadamente, restringem-se as features de nó a metadados estáticos: agregados calculados sobre toda a janela temporal (como total de streams, número de dias em chart, popularidade consolidada e contagens de hits por artista) são excluídos, pois, sendo reaplicados de forma idêntica em todos os *snapshots*, introduziriam vazamento de informação futura no vetor de cada nó (Seção 4.6).

O grafo contém quatro tipos principais de arestas. A relação `performs` conecta artistas a músicas e representa autoria ou participação. A relação `has_genre` conecta artistas a gêneros. A relação `cotrajectory` conecta músicas que compartilham presença temporal nos charts e possuem trajetórias semelhantes. A relação `cooccurs` conecta gêneros que aparecem conjuntamente em agregações do dataset.

Cada tipo de aresta possui atributos específicos. Em `performs`, são registrados três atributos: o *papel do artista* na faixa, a *posição na lista de créditos* e a *primeira semana observada*. O papel é uma variável binária que distingue o artista *principal* (o primeiro nome creditado, com valor 0) dos artistas *participantes* ou convidados (*featuring*, valor 1); ele é derivado da ordem de créditos, sendo principal o artista na primeira posição da lista e participante qualquer artista nas posições seguintes. A posição na lista preserva essa ordem de forma ordinal (0, 1, 2, ...), permitindo distinguir, por exemplo, o primeiro do segundo convidado. A distinção é relevante porque a contribuição de um artista principal para a difusão de uma faixa tende a diferir da de um participante. Em `cotrajectory`, são registrados dias em conjunto, distância média de posição, tipo de chart e primeira semana observada; esses atributos de similaridade

são calculados usando apenas observações até a semana `first_seen_week` da aresta, de modo que a existência e os atributos da aresta não codificam informação de trajetórias futuras. Em `cooccurs`, são registrados peso, popularidade média, streams médios e primeira semana observada. Essa estrutura permite que o modelo diferencie relações por semântica e por momento de observação.

4.6 TEMPORALIDADE E PREVENÇÃO DE VAZAMENTO

A temporalidade é incorporada por meio do atributo `first_seen_week`. Para qualquer semana t , o modelo só pode acessar arestas observadas até aquela semana. Assim, snapshots do grafo são obtidos por filtragem temporal, sem materializar todas as versões em disco.

Essa escolha é importante porque relações como `cotrajectory` podem depender de observações futuras se forem calculadas de forma ingênua. Ao filtrar por primeira semana observada, a avaliação se aproxima do cenário real de previsão: em uma data t , o modelo deve prever o futuro usando apenas músicas, atributos e relações disponíveis até t .

A prevenção de vazamento não se restringe às arestas. Como o mecanismo de *snapshots* filtra apenas arestas e reutiliza os vetores de nó inalterados em cada semana, qualquer atributo de nó derivado da trajetória de uma música ou artista nos charts (número total de dias em chart, streams acumulados ou contagens de hits ao longo do período) carregaria informação de toda a janela observada, inclusive do período de teste. Por isso, os vetores de nó são restritos a metadados estáticos (atributos acústicos, tipo e marcadores categóricos), e tais agregados *full-series* são deliberadamente excluídos da representação.

A formulação por snapshots semanais foi escolhida por compatibilidade com o custo computacional e com o grão temporal dos dados processados. Modelos temporais contínuos, como o TGN, permanecem como alternativa para trabalhos futuros, em que eventos de adoção de tendências em vídeo curto poderiam ser representados com resolução temporal mais fina.

→ SABER JUSTIFICAR

4.7 MODELO PROPOSTO

O modelo proposto, denominado MUSICDIFFUSIONGNN, combina uma rede neural em grafo heterogêneo com um componente recorrente temporal. A arquitetura é organizada em dois módulos desacoplados: um *codificador espacial*, que produz uma representação vetorial para cada música a partir de um *snapshot* do grafo em uma dada semana, e uma *cabeça temporal*, que consome a sequência de representações de uma música ao longo de uma janela de semanas e prevê seu *rank-score* futuro. Esse desacoplamento é deliberado: como o codificador depende apenas da estrutura observável até a semana t , sua saída pode ser calculada uma única vez por semana e reutilizada por todas as músicas avaliadas naquele instante, reduzindo o custo de treinamento sobre as ~260 semanas da janela temporal.

SABER EXPLICAR DE FORMA DIDÁTICA

4.7.1 Codificador espacial heterogêneo

Seja $G_t = \text{MASK_UNTIL}(G, t)$ o snapshot do grafo contendo apenas as arestas cuja primeira observação ocorre até a semana t (Seção 4.6, atributo `first_seen_week`). O codificador é uma rede *HeteroGraphSAGE* (Hamilton et al., 2017) com L camadas de passagem de mensagens, em que cada tipo de relação $r \in \mathcal{R}$ possui parâmetros próprios. Para um nó v e uma relação r na camada ℓ , a mensagem agregada dos vizinhos segue a formulação do GraphSAGE:

$$\mathbf{h}_v^{(r, \ell)} = \mathbf{W}_{r, \text{self}}^{(\ell)} \mathbf{h}_v^{(\ell-1)} + \mathbf{W}_{r, \text{viz}}^{(\ell)} \cdot \text{mean}_{u \in \mathcal{N}_r(v)} \mathbf{h}_u^{(\ell-1)}, \quad (4.2)$$

em que $\mathcal{N}_r(v)$ é a vizinhança de v pela relação r , e $\mathbf{W}_{r, \text{self}}^{(\ell)}$ e $\mathbf{W}_{r, \text{viz}}^{(\ell)}$ são matrizes de pesos específicas da relação. Como cada nó pode ser destino de múltiplas relações, as contribuições são combinadas por soma entre relações, seguida de não linearidade:

$$\mathbf{h}_v^{(\ell)} = \text{ReLU} \left(\sum_{r \in \mathcal{R}(v)} \mathbf{h}_v^{(r, \ell)} \right), \quad (4.3)$$

onde $\mathcal{R}(v)$ é o conjunto de relações que têm o tipo de v como destino. Entre camadas consecutivas aplica-se *dropout* às representações intermediárias. As representações iniciais $\mathbf{h}_v^{(0)}$ correspondem aos vetores de atributos de cada tipo de nó descritos na Seção 4.5 (12 dimensões para música, 1 para artista e um *embedding* aprendido de 32 dimensões para gênero). Após L camadas, a saída de interesse é a matriz de *embeddings* de música $\mathbf{Z}_{\text{music}}^{(t)} \in \mathbb{R}^{N_{\text{music}} \times d}$, onde d é a dimensão oculta.

Além das quatro relações semânticas (`performs`, `has_genre`, `cotrajectory` e `cooccurs`), inclui-se a relação reversa `genre → artist` derivada de `has_genre`. Essa adição permite que o sinal de gênero, que de outra forma só receberia mensagens, propague-se de volta aos artistas e, em uma camada subsequente, alcance as músicas. Essa é uma das razões para empilhar $L \geq 2$ camadas: a informação de gênero só chega às músicas após dois passos de mensagem (`genre → artist → music`).

4.7.2 Snapshots temporais e banco de *embeddings*

A dimensão temporal é incorporada calculando-se o codificador sobre os snapshots G_t exigidos por uma janela de previsão. Para um conjunto de semanas distintas $\{t_1, \dots, t_m\}$ requeridas por um *minibatch*¹, monta-se um *banco de embeddings* $\mathcal{B} = \{t \mapsto \mathbf{Z}_{\text{music}}^{(t)}\}$ (uma tabela de consulta que associa cada semana t à matriz de representações $\mathbf{Z}_{\text{music}}^{(t)}$ das músicas naquela semana), em que cada entrada é calculada uma única vez e compartilhada por todas as músicas que precisam daquela semana. O banco é mantido dentro do *grafo de autograd*² do

¹Um *minibatch* é o subconjunto de amostras (aqui, pares de música e semana-alvo) processado em conjunto a cada passo de atualização dos pesos, em vez de todo o conjunto de treino de uma só vez; é a unidade do treinamento estocástico por gradiente.

²O *grafo de autograd* (diferenciação automática) é a estrutura que o *framework* constrói para registrar as operações do passo à frente e, a partir dela, calcular os gradientes na retropropagação. Manter o banco “dentro” desse grafo

minibatch, de modo que o codificador é treinado de ponta a ponta junto com a cabeça temporal. Como o snapshot de uma semana t contém apenas arestas com $\text{first_seen_week} \leq t$, a construção elimina o vazamento temporal pela via das arestas; a ausência de vazamento pelas *features de nó* é garantida separadamente, restringindo-as a metadados estáticos (Seção 4.6).

Em razão do volume da relação *cotrajjectory* (mais de 660 mil arestas), aplica-se, durante o treinamento, uma subamostragem aleatória dessas arestas por snapshot até um teto fixo de $3,0 \times 10^4$ arestas, técnica análoga ao *DropEdge*. Essa medida cumpre dupla função: controla o consumo de memória do banco diferenciável e atua como regularização estrutural. O teto é aplicado apenas durante o treinamento; na avaliação e nos resultados reportados, o codificador opera sobre o grafo *cotrajjectory* completo, sem subamostragem. Assim, ele não constitui um hiperparâmetro do modelo avaliado, mas um orçamento de memória (com efeito colateral de regularização) restrito à fase de otimização.

4.7.3 Cabeça temporal recorrente

Para prever o *rank-score* de uma música i em uma semana-alvo w e em um chart c , define-se uma janela causal de comprimento W composta pelas semanas $[w - W, \dots, w - 1]$. A cabeça temporal recebe a sequência de *embeddings* dessa música ao longo da janela,

$$\mathbf{s}_i = (\mathbf{z}_i^{(w-W)}, \dots, \mathbf{z}_i^{(w-1)}), \quad \mathbf{z}_i^{(t)} = \mathbf{Z}_{\text{music}}^{(t)}[i], \quad (4.4)$$

em que posições anteriores à primeira semana observada da música (ou a índices negativos) são preenchidas com zeros e sinalizadas por uma máscara, evitando que passos sem informação influenciem o estado recorrente. A sequência é processada por uma GRU de uma camada (Cho et al., 2014), cujo estado oculto final $\mathbf{h}_i$ resume a trajetória da música. Esse estado alimenta um perceptron multicamadas (MLP) com não linearidade ReLU e *dropout*, e a previsão é restringida ao intervalo do alvo por meio de uma sigmoide escalada:

$$\hat{y}_i = 0,5 \cdot \sigma(\text{MLP}(\mathbf{h}_i)), \quad (4.5)$$

garantindo $\hat{y}_i \in [0, 0,5]$ sem necessidade de truncamento posterior, em consonância com a normalização do *rank-score* descrita na Seção 4.3.

4.7.4 Função de perda, otimização e regularização

O modelo é treinado por minimização do erro quadrático médio (MSE) entre a previsão $\hat{y}_i$ e o *rank-score* semanal observado, usando o otimizador Adam. A regularização combina três mecanismos: *dropout* no codificador e na cabeça, decaimento de pesos (*weight decay*) no otimizador e *early stopping* guiado pelo MSE de validação. A Tabela 4.1 resume os

significa não desacoplar (*detach*) as representações: os gradientes da perda fluem de volta pelo codificador, que é assim ajustado *de ponta a ponta* junto com a cabeça temporal, em vez de congelado.

hiperparâmetros do modelo. Os quatro primeiros (janela temporal W , dimensão oculta d , número de camadas L e taxa de aprendizado) são explorados por busca em grade, totalizando $3 \times 2 \times 2 \times 2 = 24$ configurações; os demais (*dropout*, *weight decay* e orçamento de épocas) são mantidos fixos nos valores indicados. A configuração final é selecionada pelo menor MSE de validação, mantendo o conjunto de teste reservado.

Tabela 4.1: Espaço de hiperparâmetros do modelo proposto.

Hiperparâmetro	Valores
Janela temporal W (semanas)	{4, 8, 12}
Dimensão oculta d	{64, 128}
Camadas do codificador L	{2, 3}
Taxa de aprendizado	$\{10^{-3}, 5 \times 10^{-4}\}$
<i>Dropout</i>	0,2
<i>Weight decay</i>	10^{-5}
Épocas máximas / paciência	100 / 10

7 ESTUDAR HIPERPARÂMETROS

4.8 PROTOCOLO EXPERIMENTAL

A avaliação usa *splits* temporais sobre a série agregada por semana. O *rank-score* diário é consolidado em um alvo semanal $y_{\text{week}}(i, c, w)$, definido como a média dos valores diários da música i no chart c dentro da semana ISO w . Essa agregação alinha o grão da série ao grão das relações do grafo, cujas arestas têm resolução semanal (Seção 4.6), e reduz o comprimento das séries de ~ 1.900 para ~ 260 passos. O período até junho de 2020 é usado para treinamento; de julho a dezembro de 2020, para validação; e 2021 é reservado para teste. Como os limites de *split* são definidos por semana, cada semana pertence a exatamente uma partição, impedindo que o modelo seja avaliado sobre instantes vistos durante o treinamento.

Serão executados dois regimes de avaliação que compartilham o mesmo modelo e os mesmos pesos. O primeiro é a *previsão genuína (forecasting)*: o modelo prevê y_{week} na partição futura mantida em reserva, usando apenas a janela causal de semanas anteriores ao instante de previsão. O segundo é o *ajuste retroativo*: a curva de cada música é reconstruída de forma *teacher-forced* ao longo de todo o seu período ativo, aproximando-se do ajuste *in-sample* do baseline SIR. O regime retroativo cumpre função comparativa com o baseline epidemiológico, enquanto o regime de previsão mede a capacidade preditiva efetiva sobre dados não vistos.

A métrica principal é o RMSE entre $\hat{y}_{\text{week}}$ e y_{week} , reportado separadamente para viralidade (Viral 50) e sucesso (Top 200), de forma coerente com a separação adotada no baseline SIR. Como referência ingênua de previsão, adota-se a *persistência*, $\hat{y}(w) = y(w-1)$, que repete o último valor observado. A persistência é um baseline reconhecidamente forte em séries temporais e estabelece o piso que o modelo neural precisa superar: o critério mínimo de sucesso desta etapa é que a GNN heterogênea temporal apresente RMSE inferior ao da persistência em ambos os

regimes de chart. Como métrica complementar, considera-se o acerto direcional (se o modelo acerta a tendência de subida ou queda da música), a ser incorporado na avaliação final.

A comparação direta com o baseline SIR exige conciliar o grão semanal do modelo proposto com o grão diário em que o SIR foi originalmente ajustado. Optou-se por recalcular o erro do SIR sobre o mesmo eixo semanal, de modo que ambos os modelos são avaliados na mesma resolução temporal e sobre o mesmo subconjunto de músicas, condição necessária para uma comparação justa. Os resultados dessa avaliação comparativa são apresentados no Capítulo 5.

4.9 SÍNTESE DO CAPÍTULO

A metodologia proposta transforma séries de charts musicais em um problema de previsão temporal sobre grafo heterogêneo. O baseline SIR oferece uma referência interpretável e já consolidada na literatura brasileira recente. O grafo heterogêneo adiciona relações entre músicas, artistas e gêneros, enquanto a arquitetura temporal busca explorar a evolução dessas relações sem vazamento de informação futura. Com isso, a avaliação poderá responder se a estrutura heterogênea temporal melhora a modelagem de difusão musical em relação a modelos epidemiológicos populacionais.

5 RESULTADOS PARCIAIS

Este capítulo apresenta os resultados já consolidados do estudo. O trabalho está organizado em etapas incrementais: a reprodução do baseline epidemiológico, a construção do grafo heterogêneo temporal, o treinamento da GNN temporal e a avaliação comparativa entre a GNN e o baseline SIR nos dois regimes descritos na metodologia. O objetivo é triplo: demonstrar que o pipeline reproduz fielmente o baseline de referência, evidenciar que o grafo construído possui estrutura suficiente para justificar a abordagem neural, e comparar os dois modelos tanto na reconstrução retroativa das trajetórias (Modo 1) quanto na previsão de curto horizonte fora da amostra (Modo 2). Adianta-se que os modelos são complementares: o SIR, por ajustar dois parâmetros a cada curva completa, é mais preciso na reconstrução *in-sample*, ao passo que a GNN, um preditor global e congelado, supera o SIR de forma consistente e estatisticamente significativa na tarefa de previsão, que é o seu uso pretendido.

5.1 REPRODUÇÃO DO BASELINE SIR

A primeira etapa teve como meta reproduzir o ajuste SIR do trabalho de referência (Oliveira et al., 2025b) sobre os charts brasileiros, como pré-requisito metodológico para qualquer comparação posterior. O ajuste foi conduzido sobre o subconjunto $viral \cap hit$ (músicas presentes simultaneamente no Top 200 e no Viral 50), totalizando 1.981 músicas no pipeline local, valor próximo às 1.977 reportadas no trabalho original. Para cada música, as séries de viralidade e sucesso foram ajustadas de forma independente, estimando os parâmetros β , γ e a razão $R_0 = \beta/\gamma$.

A Tabela 5.1 compara as métricas obtidas com os alvos do trabalho de referência. Todos os critérios mínimos pré-acordados foram atingidos: o RMSE de viralidade e de sucesso ficou dentro da margem de 10% dos valores de referência, o teste de Mann-Whitney permaneceu fortemente significativo, com valor- p muito abaixo de qualquer limiar convencional, e o ajuste convergiu para 100% das séries.

Tabela 5.1: Critério de reprodução do baseline SIR.

Métrica	Alvo (referência)	Obtido	Status
RMSE viralidade	$\approx 0,028$	0,0289	Atingido
RMSE sucesso	$\approx 0,052$	0,0471	Atingido
Mann-Whitney p	$p \ll 0,05$	$1,61 \times 10^{-39}$	Atingido
Subset $viral \cap hit$	1.977	1.981	Atingido
Convergência do ajuste	100%	100%	Atingido

A reprodução fiel cumpre uma função metodológica central: sem ela, a comparação posterior entre GNN e SIR não seria defensável, pois não haveria garantia de que o pipeline de

dados e de avaliação está alinhado ao da literatura. Além de validar o pipeline, a análise das séries trouxe duas observações que orientam as próximas etapas. A primeira é que músicas com permanência longa nos charts (mais de cem dias ativos, cerca de 37% do Top 200) exibem padrão multi-onda, que o ajuste SIR de onda única captura mal e que eleva o RMSE médio, ainda que a mediana permaneça dentro da tolerância; esse comportamento justifica conceitualmente as extensões multi-onda do SIR discutidas no Capítulo 3 (Oliveira et al., 2025a), mesmo que não tenham sido reimplementadas aqui. A segunda é a necessidade de investigar eventuais diferenças entre média e mediana na forma como o trabalho de referência reporta o erro, o que pode afetar a comparação exata das métricas de reprodução.

5.2 GRAFO HETEROGÊNEO TEMPORAL

A segunda etapa construiu o grafo heterogêneo temporal descrito no Capítulo 4. O grafo final contém 6.526 nós de música, 1.701 nós de artista e 530 nós de gênero. As contagens de música e gênero ficaram dentro das tolerâncias estabelecidas, e o número de artistas coincidiu exatamente com o esperado. O universo de música é maior que o subconjunto *viral* $\cap$ *hit* por decisão de projeto: incluir músicas presentes apenas no Top 200 enriquece o contexto estrutural disponível ao modelo.

A Tabela 5.2 resume as contagens por tipo de aresta. A relação *cotrajectory* domina o grafo, com mais de 660 mil arestas, refletindo o grande número de pares de músicas que compartilham trajetória nos charts. As demais relações (autoria, associação a gênero e coocorrência de gêneros) contribuem com volumes menores, porém semanticamente distintos.

Tabela 5.2: Contagens por tipo de aresta no grafo heterogêneo.

Tipo de aresta	Contagem
artist $\rightarrow$ performs $\rightarrow$ music	9.274
artist $\rightarrow$ has_genre $\rightarrow$ genre	3.344
music $\rightarrow$ cotrajectory $\rightarrow$ music	664.577
genre $\rightarrow$ cooccurs $\rightarrow$ genre	9.866

A análise topológica indica que o grafo possui estrutura rica, e não conexões aleatórias. O coeficiente de *clustering* médio é elevado tanto em *cotrajectory* (0,5126) quanto em *cooccurs* (0,6040), sugerindo agrupamentos coesos de músicas e de gêneros. A detecção de comunidades por Louvain sobre o subgrafo de gêneros identificou agrupamentos coerentes, com as cinco maiores comunidades reunindo 136, 119, 96, 60 e 43 gêneros, e apenas cinco comunidades isoladas de pequeno porte. As distribuições de grau são fortemente assimétricas, característica esperada em redes culturais, com poucos nós de altíssimo grau e uma longa cauda de nós pouco conectados.

A construção foi acompanhada de um conjunto de validações automatizadas (nove critérios), que verificam desde a contagem de nós e a ausência de arestas órfãs até propriedades temporais e de integração com a arquitetura neural. Entre elas destacam-se a garantia de que

7) SABER EXPLICAR

todas as músicas do subconjunto $viral \cap hit$ estão presentes no grafo, a verificação de que o atributo `first_seen_week` permanece no intervalo válido em todas as arestas, e a confirmação de que o mecanismo de *snapshots* temporais é monotônico, isto é, o grafo observável até uma semana está contido no grafo observável em semanas posteriores, propriedade essencial para evitar vazamento temporal. Um *smoke-test* confirmou ainda que a arquitetura HeteroGraphSAGE percorre o grafo e produz embeddings de música com a dimensão esperada, sem valores inválidos. Satisfeitos os nove critérios, o grafo é considerado válido para a etapa de modelagem, em particular quanto à ausência de vazamento temporal.

5.3 AVALIAÇÃO DUPLA: GNN TEMPORAL *VERSUS* SIR

A terceira etapa treinou a GNN heterogênea temporal (arquitetura HeteroGraphSAGE seguida de uma unidade recorrente GRU, janela temporal de doze semanas, dimensão latente 128 e três camadas de convolução) e a avaliou contra o baseline SIR sobre exatamente o mesmo eixo semanal e o mesmo subconjunto de músicas, condição indispensável para uma comparação justa. O modelo selecionado atingiu erro quadrático médio de validação de $7,5 \times 10^{-4}$. A avaliação segue dois regimes distintos e complementares. As pequenas variações no número de músicas entre etapas (1.981 no ajuste SIR, 1.955 no Modo 1 e 1.933 no Modo 2) refletem exigências mínimas específicas de cada regime (por exemplo, uma janela causal completa de W semanas antes da origem de previsão), de modo que uma música é excluída apenas da etapa em que a exigência correspondente não é satisfeita.

5.3.1 Modo 1: reconstrução retroativa

No Modo 1, cada modelo reconstrói a trajetória semanal inteira de uma música a partir de uma semente inicial. Trata-se de uma tarefa *in-sample* para o SIR, cujos parâmetros β e γ são ajustados individualmente à curva completa de cada música; a GNN, ao contrário, é um modelo global e congelado que simula a trajetória às cegas. A Tabela 5.3 mostra que, nesse cenário, o SIR obtém menor RMSE em ambos os regimes, tanto na métrica de espectro completo quanto na restrita às semanas em que a música figura efetivamente no chart (*on-chart*).

Tabela 5.3: Modo 1: RMSE médio da reconstrução retroativa (1.955 músicas por regime).

Regime	GNN	SIR	GNN (on-chart)	SIR (on-chart)
Viral 50	0,0266	0,0141	0,1915	0,1756
Top 200	0,0632	0,0343	0,1637	0,1262

Essa vantagem do SIR é esperada e não contradiz a hipótese do trabalho: comparar um modelo global congelado, que prevê a partir de uma semente de doze semanas, contra um ajuste de dois parâmetros livres feito sobre a curva inteira favorece estruturalmente o segundo. Trata-se, portanto, de uma limitação do regime *in-sample*, e não uma falha do modelo. O ponto relevante é que a diferença se estreita fortemente quando se olham apenas as semanas *on-chart*, onde a

dinâmica de fato importa: no regime Viral 50 os erros ficam próximos (0,1915 contra 0,1756). A mesma leitura se aplica ao subgrupo de *hits* de longa permanência (mais de noventa dias em chart, 806 músicas), no qual o SIR mantém vantagem (RMSE médio 0,0605 contra 0,0998 da GNN): são justamente as trajetórias multi-onda que o ajuste curva-a-curva melhor captura.

5.3.2 Modo 2: previsão de curto horizonte

O Modo 2 mede a tarefa de fato pretendida para a GNN: previsão causal, a k semanas à frente, usando somente informação disponível até a origem da previsão. Aqui o SIR é reajustado de forma causal: β e γ são estimados por mínimos quadrados não lineares apenas sobre os pontos observados até a semana de origem, e a curva prevista resulta da integração da EDO por k semanas a partir do último estado estimado, o que o coloca em pé de igualdade metodológica com a GNN. Incluiu-se ainda um baseline de persistência (repetir o último valor observado). A Tabela 5.4 apresenta o RMSE por horizonte e regime.

Tabela 5.4: Modo 2: RMSE da previsão causal a k semanas (1.933 músicas pareadas por célula).

Regime	k	GNN	SIR	Persist.
Viral 50	1	0,0261	0,0368	0,0267
	2	0,0345	0,0604	0,0375
	4	0,0444	0,0798	0,0538
Top 200	1	0,0238	0,0458	0,0231
	2	0,0370	0,0524	0,0360
	4	0,0513	0,0636	0,0520

A GNN supera o SIR em *todos* os seis cenários (dois regimes $\times$ três horizontes). A vantagem é estatisticamente significativa: o teste de Wilcoxon pareado por música rejeita a hipótese nula em todas as células, com valores- p entre $6,5 \times 10^{-4}$ e $5,4 \times 10^{-32}$, e a GNN apresenta menor erro em 64% a 77% das músicas, conforme o horizonte. A margem sobre o SIR também cresce com o horizonte no regime Viral 50 (de 29% em $k = 1$ para 44% em $k = 4$), indicando que a estrutura do grafo é especialmente útil quando a extrapolação epidemiológica se degrada. O baseline de persistência é forte nos horizontes curtos (comportamento esperado, pois a popularidade varia pouco de uma semana para a seguinte) e, no regime Top 200, supera marginalmente a GNN tanto em $k = 1$ (0,0231 contra 0,0238) quanto em $k = 2$ (0,0360 contra 0,0370); as diferenças são pequenas, mas, como no Modo 1, a GNN não supera a persistência em todas as células. No regime Viral 50, a GNN supera a persistência em todos os horizontes avaliados; no Top 200, apenas no horizonte mais longo ($k = 4$: 0,0513 contra 0,0520). Frente ao SIR, por outro lado, a GNN é consistentemente superior nos seis cenários avaliados. Esse resultado, a GNN como o melhor preditor frente ao baseline epidemiológico, constitui a contribuição central do estudo. Frente à persistência, a GNN é superior no Viral 50, mas apenas parcialmente no Top 200, onde só a supera em $k = 4$.

5.4 DISCUSSÃO PARCIAL

Os resultados consolidados sustentam três conclusões parciais. Primeiro, o baseline epidemiológico foi reproduzido dentro das margens da literatura, validando o pipeline de dados e avaliação. Segundo, a topologia do grafo heterogêneo (*clustering* elevado, comunidades de gênero coerentes e distribuições de grau realistas) sugere que existe sinal estrutural a ser explorado por uma GNN. Terceiro, e mais importante, a avaliação dupla mostra que GNN e SIR são complementares, cada um superior na tarefa para a qual é estruturalmente adequado.

A leitura conjunta dos dois modos é o ponto central. Na reconstrução retroativa (Modo 1), o SIR leva vantagem, mas por um motivo metodológico transparente: ele ajusta dois parâmetros livres à curva completa de cada música, enquanto a GNN simula às cegas a partir de uma semente curta. Já na previsão causal de curto horizonte (Modo 2), que é o uso pretendido de um preditor e a pergunta de pesquisa efetivamente relevante, a GNN supera o SIR em todos os horizontes e regimes, com significância estatística forte. Em outras palavras, um preditor neural treinado sobre esse grafo supera o modelo epidemiológico puramente temporal, com vantagem que cresce à medida que o horizonte de previsão aumenta. Atribuir esse ganho especificamente à estrutura relacional (coautoria, gênero e cotrajetória), e não apenas à maior flexibilidade de um modelo neural frente a um ajuste paramétrico de dois graus de liberdade, é, neste estágio, hipótese e não achado estabelecido.

Resta como trabalho em andamento testar diretamente essa hipótese, por meio da análise de interpretabilidade da GNN (ablação por tipo de aresta, importância de grupos de atributos e extração de análogos de β , γ e R_0 a partir das trajetórias previstas) e de um baseline neural sem grafo (por exemplo, uma GRU sobre a série de cada música isolada), que isola o ganho atribuível à flexibilidade do modelo daquele atribuível à estrutura relacional. Os resultados completos serão incorporados na versão final da dissertação.

6 CRONOGRAMA E PRÓXIMOS PASSOS

Este capítulo consolida o que resta para concluir a pesquisa de mestrado e apresenta o cronograma previsto para essas atividades. O trabalho descrito nos capítulos anteriores já entregou três resultados centrais (Capítulo 5): a reprodução fiel do baseline epidemiológico SIR, a construção e validação do grafo heterogêneo temporal, e a avaliação dupla que mostra a GNN heterogênea temporal superando o SIR de forma estatisticamente significativa na tarefa de previsão causal de curto horizonte. As etapas restantes têm dois propósitos: isolar quanto do ganho preditivo se deve especificamente à estrutura relacional do grafo, e verificar se esse ganho é robusto à escolha da arquitetura de codificação, antes da redação final e da defesa.

6.1 PRÓXIMOS PASSOS

As atividades a seguir dão continuidade direta às pendências já identificadas na discussão parcial (Seção 5.3) e detalham as investigações necessárias para fechar a dissertação.

ENTENDER E JUSTIFICAR

- **Baseline neural sem grafo.** Treinar um preditor puramente temporal, isto é, uma GRU aplicada à série de cada música isoladamente, sem acesso às relações do grafo. Esse baseline isola o ganho atribuível à flexibilidade de um modelo neural daquele atribuível à estrutura relacional (coautoria, gênero e cotrajetória), respondendo diretamente à ressalva levantada na Seção 5.3.
- **Interpretabilidade e ablação.** Conduzir a análise de interpretabilidade da GNN prevista na metodologia: ablação por tipo de aresta (removendo `performs`, `has_genre`, `cotrajectory` ou `cooccurs` e medindo o impacto no RMSE de previsão), avaliação da importância de grupos de atributos e extração de análogos de β , γ e R_0 a partir das trajetórias previstas, aproximando a leitura neural da leitura epidemiológica.
- **Experimentos com arquitetura alternativa de GNN.** O codificador atual, *Hetero-GraphSAGE*, agrega vizinhos por média (Seção 4.7), atribuindo peso uniforme a cada relação e a cada vizinho. Pretende-se substituí-lo por um codificador heterogêneo baseado em atenção, como o *Heterogeneous Graph Transformer* (Hu et al., 2020) ou uma variante com atenção por relação (Veličković et al., 2018; Wang et al., 2019), mantendo fixos a cabeça temporal, o protocolo de *splits* e o mecanismo de prevenção de vazamento, de modo a garantir uma comparação justa. Esse experimento cumpre duas funções: (i) verificar se a vantagem preditiva observada é robusta à escolha de arquitetura, e não um artefato do *HeteroGraphSAGE*; e (ii) explorar se pesos de atenção aprendidos (por exemplo, distinguindo o artista principal do participante ou ponderando

vizinhos de cotrajetória) melhoram a previsão e fornecem interpretabilidade adicional, conectando-se ao item anterior.

- **Análise comparativa e redação.** Consolidar os resultados dos três experimentos anteriores em uma comparação única (SIR, persistência, GNN sem grafo, *HeteroGraphSAGE* e arquitetura alternativa), sob as mesmas métricas e o mesmo eixo semanal, e redigir os capítulos finais da dissertação, incluindo a discussão completa e a conclusão.
- **Defesa e publicação.** Defender a dissertação e organizar as contribuições principais em um artigo para submissão a um evento ou periódico da área.

6.2 CRONOGRAMA

A Tabela 6.1 apresenta a distribuição prevista dessas atividades ao longo dos meses, a partir da qualificação. O cronograma reserva os meses iniciais para os experimentos ainda em aberto (baseline sem grafo, ablação e arquitetura alternativa), concentra a redação após a consolidação dos resultados e prevê defesa e submissão nos meses finais.

Tabela 6.1: Cronograma das atividades restantes (ago. 2026 a jan. 2027).

Atividade	Ago	Set	Out	Nov	Dez	Jan
Qualificação	×					
Baseline neural sem grafo		×				
Interpretabilidade e ablação		×	×			
Arquitetura alternativa de GNN			×	×		
Análise comparativa				×	×	
Redação da dissertação					×	×
Defesa						×
Publicação						×

REFERÊNCIAS

- Bass, F. M. (1969). A new product growth for model consumer durables. *Management Science*, 15(5):215–227.
- Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H. e Bengio, Y. (2014). Learning phrase representations using RNN encoder-decoder for statistical machine translation. Em *Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP)*.
- Dhanaraj, R. e Logan, B. (2005). Automatic prediction of hit songs. Em *Proceedings of the International Society for Music Information Retrieval Conference (ISMIR)*.
- Goel, S., Anderson, A., Hofman, J. e Watts, D. J. (2016). The structural virality of online diffusion. *Management Science*, 62(1):180–196.
- Granovetter, M. (1978). Threshold models of collective behavior. *American Journal of Sociology*, 83(6):1420–1443.
- Hamilton, W. L., Ying, R. e Leskovec, J. (2017). Inductive representation learning on large graphs. Em *Advances in Neural Information Processing Systems*.
- Hu, Z., Dong, Y., Wang, K. e Sun, Y. (2020). Heterogeneous graph transformer. Em *The Web Conference (WWW)*.
- Interiano, M., Kazemi, K., Wang, L., Yang, J., Yu, Z. e Komarova, N. L. (2018). Musical trends and predictability of success in contemporary songs in and out of the top charts. *Royal Society Open Science*, 5(5):171274.
- Kazemi, S. M., Goel, R., Jain, K., Kobayez, I., Sethi, A., Forsyth, P. e Poupart, P. (2020). Representation learning for dynamic graphs: A survey. *Journal of Machine Learning Research*, 21(70):1–73.
- Kempe, D., Kleinberg, J. e Tardos, E. (2003). Maximizing the spread of influence through a social network. Em *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*.
- Kipf, T. N. e Welling, M. (2017). Semi-supervised classification with graph convolutional networks. Em *International Conference on Learning Representations*.
- Oliveira et al. (2025a). Modelagem multi-onda da difusão de músicas em charts brasileiros. Em *IEEE/ACM International Conference on Advances in Social Networks Analysis and Mining (ASONAM)*. TODO: confirmar título exato, autores completos e DOI.

- Oliveira, G. P., Vassio, L., Couto da Silva, A. P. e Moro, M. M. (2025b). Modeling music popularity as an epidemic: Insights from the Brazilian market. Em *Brazilian Workshop on Social Network Analysis and Mining (BraSNAM)*. SBC.
- Pachet, F. e Roy, P. (2008). Hit song science is not yet a science. Em *Proceedings of the International Society for Music Information Retrieval Conference (ISMIR)*.
- Pareja, A., Domeniconi, G., Chen, J., Ma, T., Suzumura, T., Kanezashi, H., Kaler, T., Schardl, T. B. e Leiserson, C. E. (2020). EvolveGCN: Evolving graph convolutional networks for dynamic graphs. Em *Proceedings of the AAAI Conference on Artificial Intelligence*.
- Rogers, E. M. (2003). *Diffusion of Innovations*. Free Press, New York, 5th edition.
- Rossi, E., Chamberlain, B., Frasca, F., Eynard, D., Monti, F. e Bronstein, M. (2020). Temporal graph networks for deep learning on dynamic graphs. Em *ICML Workshop on Graph Representation Learning and Beyond*.
- Sankar, A., Wu, Y., Gou, L., Zhang, W. e Yang, H. (2020). DySAT: Deep neural representation learning on dynamic graphs via self-attention networks. Em *Proceedings of the ACM International Conference on Web Search and Data Mining (WSDM)*.
- Schlichtkrull, M., Kipf, T. N., Bloem, P., van den Berg, R., Titov, I. e Welling, M. (2018). Modeling relational data with graph convolutional networks. Em *European Semantic Web Conference (ESWC)*.
- Seo, Y., Defferrard, M., Vandergheynst, P. e Bresson, X. (2018). Structured sequence modeling with graph convolutional recurrent networks. Em *International Conference on Neural Information Processing (ICONIP)*.
- Seufitelli, D. B. et al. (2023). MGD+: An enhanced music genre dataset with success-based networks. Em *Dataset Showcase Workshop (DSW)*, páginas 36–47. SBC.
- Veličković, P., Cucurull, G., Casanova, A., Romero, A., Liò, P. e Bengio, Y. (2018). Graph attention networks. Em *International Conference on Learning Representations (ICLR)*.
- Wang, X., Ji, H., Shi, C., Wang, B., Ye, Y., Cui, P. e Yu, P. S. (2019). Heterogeneous graph attention network. Em *The World Wide Web Conference (WWW)*.
- Watts, D. J. (2002). A simple model of global cascades on random networks. *Proceedings of the National Academy of Sciences*, 99(9):5766–5771.
- Xu, D., Ruan, C., Korpeoglu, E., Kumar, S. e Achan, K. (2020). Inductive representation learning on temporal graphs. Em *International Conference on Learning Representations (ICLR)*.

- Yang, L.-C., Chou, S.-Y., Liu, J.-Y., Yang, Y.-H. e Su, A. W. Y. (2017). Revisiting the problem of audio-based hit song prediction using convolutional neural networks. Em *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*.
- Zhao, Q., Erdogdu, M. A., He, H. Y., Rajaraman, A. e Leskovec, J. (2015). SEISMIC: A self-exciting point process model for predicting tweet popularity. Em *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*.